


	contenido del corpus del resto de las instrucciones, de modo que texto contenido en un documento ingestado no pueda alterar el comportamiento, las reglas o las restricciones del asistente.	
RNF-036	El sistema debe procesar y almacenar el contenido de los documentos ingestados utilizando codificación UTF-8, preservando correctamente tildes, la letra "ñ" y demás caracteres propios del idioma español, sin pérdida ni alteración de datos.	RF-023 RF-017

8. MODELO DE DATOS



8.1. Resumen del modelo

Propiedad	Valor
Motor	PostgreSQL 16 + extensión pgvector (base de datos vectorizada que sustenta el RAG)

Propiedad	Valor
Driver / acceso	AsyncPG (motor async de SQLAlchemy hacia PostgreSQL)
Arquitectura	Monolito modular
Total de tablas	13
Origen del diseño	ERD «Diagrama Entidad–Relación · IGUALAB — Modelo de Datos Depurado» entregado por el equipo, con las correcciones aplicadas tras su revisión (puntos ✎ anotados en cada ficha)
Alcance retirado	Se quitaron módulos (Configuración, catálogo de roles, medidor LLM separado) → se retiraron 5 tablas del diseño v2 y se añadieron 4 nuevas

8.2. El modelo por dominios (6 dominios — refleja el ERD vigente)

Dominio	Tablas	Propósito
IDENTIDAD Y ACCESO	usuarios · sesiones · tokens_recuperacion	Accounts of access, sesiones explícitas (JWT/sid) y recuperación de contraseña single-use.
EMPRESAS E INGESTA	empresas · documentos · fragmentos_documento	Cadena de contenido fuente: catálogo de empresas, pipeline de ingesta .md y fragmentos vectorizados.
ANÁLISIS GRI	catalogo_gri · gri_analisis · sanciones	El estándar GRI (referencia) y la tabla única de resultados del análisis (códigos, citas, sanciones).
ASISTENTE RAG	consultas_asistente · consulta_citas	Persistencia de cada consulta al RAG con sus citas · fuentes (post-verificación de IDs).
REPORTES	reportes_prospeccion	Entregable PDF inmutable + snapshot JSONB congelado a la fecha de emisión.
AUDITORÍA	auditoria	Bitácora x-only de eventos sensibles (solo INSERT; UTC).

8.3. Entidades y relaciones (modelo conceptual)

Cadena principal del negocio:

empresa → documento (.md) → fragmentos (vectorizados) → gri_analisis → reportes_prospeccion,
con: usuarios (quién hace qué) · auditoria (eventos sensibles) · catalogo_gri (El estándar),
consultas_asistente + consulta_citas (Asistente RAG).

Relaciones (todas 1:N salvo indicación):

1. Un **usuario** abre muchas **sesiones** y crea muchos **tokens_recuperacion**.
2. Una **empresa** tiene muchos **documentos**; un **usuario** crea los documentos (creada_por).
3. Un **documento** se vectoriza en muchos **fragmentos_documento**; un documento produce muchas filas de **gri_analisis** y cita muchas **sanciones**.
4. Cada fila de **gri_analisis** referencia un código del **catalogo_gri** y proviene de un **fragmento** (fragmento_id — cita verificable).
5. Una **consulta_asistente** registra sus **citas** (consulta_citas) enlazadas a fragmentos.
6. Un **reporte de prospección** pertenece a una empresa (UNIQUE empresa+anho — RNF-032) y congela su **snapshot** a la fecha de emisión.

7. Todo evento sensible registra **auditoria** (append-only; FK usuario/empresa NULL cuando aplica).

8.4. Diagrama Entidad–Relación (ERD vigente)

ERD «Modelo de Datos Depurado» (13 tablas). El diagrama anterior Diagrama_bd.png queda como archivo histórico.

8.5. Restricciones clave (UNIQUE y reglas BD)

Restricción	Descripción
UNIQUE parcial en usuarios.rol (WHERE rol='superadmin')	Un solo Superadmin en toda la tabla — la transferencia es transacción doble atómica (RS-01).
UNIQUE case-insensitive usuarios.correo (índice lower(correo))	Correo único de dominio autorizado (RN-007).
UNIQUE documentos.sha256	El mismo contenido nunca se ingesta dos veces (RNF-010).
UNIQUE parcial (empresa_id, anho, tipo) WHERE estado='indexado'	Unicidad documental por empresa/año/tipo — solo para documentos exitosos.
UNIQUE (documento_id, indice) en fragmentos_documento	Posición única del fragmento dentro del documento.
UNIQUE parcial (documento_id, gri_codigo) en gri_analisis	Una sola fila de resultados por documento/código.
UNIQUE parcial (empresa_id, anho) en reportes_prospeccion	Un solo reporte por empresa/año (RNF-032).
CHECK sectores cerrados en empresas.sector	Minería · Petróleo y Gas · Energía (RN-019, en la BD).
CHECK tamano_bytes ≤ 50 MB en documentos	Límite de tamaño (RN-019).
CHECK estados ENUM	estado_ingesta, estado_gri, estado_documental, tipo_evento_auditoria.
REVOKE UPDATE, DELETE en auditoria	Append-only garantizado por la BD.

8.6. Tablas retiradas (se quitaron módulos)

Retirada	Justificación
roles	Catálogo cerrado de 2 filas — sustituido por ENUM rol_usuario + UNIQUE parcial en usuarios.rol.
configuracion	El módulo Configuración fue quitado → umbrales por variables de entorno (doc Stack §4).
uso_llm	El consumo diario se deriva de consultas_asistente (COUNT por día/modelo).

Retirada	Justificación
gri_analisis_historico	Los cambios sensibles quedan en auditoria (AJUSTE_BRECHA detalle JSONB).
reporte_detalle_snapshot	Sustituída por contenido_snapshot JSONB + PDF inmutable con hash.

8.7. Decisiones del modelo

- 8.7.1. **Sectores cerrados:** Minería, Petróleo y Gas, Energía (CHECK en la BD).
- 8.7.2. **Estado GRI asignado manualmente** por el Administrador: no existe estado_sugerido.
- 8.7.3. **Sanciones enlazadas al documento;** empresa y año se derivan de él (sin duplicar FKs).
- 8.7.4. **Embeddings almacenados en fragmentos_documento;** la dimensión depende del modelo del proveedor (fijar en migración, p. ej. 1024).
- 8.7.5. **Reporte consolidado en JSONB + PDF inmutable** (sin tabla normalizada de detalle).
- 8.7.6. **Auditoría unipersonal** separada del logging técnico y con modo append-only.
- 8.7.7. **FK de auditoría/consultas visibles** en el diagrama (líneas largas omitidas por legibilidad).

9. DICCIONARIO DE DATOS

El modelo contiene 12 tablas en la base de datos transaccional y 1 tabla en la base de datos vectorial. Las relaciones entre ambas bases se registran como referencias lógicas (REF), no como claves foráneas físicas.

Base de datos transaccional:

Tabla: usuarios

Descripción: Almacena las cuentas de usuario, sus credenciales, rol y estado de acceso al sistema.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único del usuario.	NO
nombre	200	VARCHAR	Nombre completo del usuario.	NO
correo	255	VARCHAR (UQ)	Correo electrónico único utilizado para el inicio de sesión.	NO
password_hash	255	VARCHAR	Hash seguro de la contraseña del usuario.	NO
rol	-	rol_usuario	Rol asignado al usuario, por ejemplo SUPERADMIN o ADMIN.	NO
habilitado	-	BOOLEAN	Indica si la cuenta está habilitada para acceder al sistema.	NO

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
intentos_fallidos	-	INTEGER	Cantidad acumulada de intentos fallidos de autenticación.	NO
bloqueado_hasta	-	TIMESTAMPTZ	Fecha y hora hasta la que la cuenta permanece bloqueada.	SÍ
creado_en	-	TIMESTAMPTZ	Fecha y hora de creación de la cuenta.	NO

Tabla: sesiones

Descripción: Registra las sesiones iniciadas por los usuarios y permite controlar su actividad y revocación.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único de la sesión.	NO
usuario_id	36	UUID (FK)	Usuario propietario de la sesión. Referencia a usuarios.id.	NO
creada_en	-	TIMESTAMPTZ	Fecha y hora en que se creó la sesión.	NO
ultima_actividad	-	TIMESTAMPTZ	Fecha y hora de la actividad más reciente de la sesión.	NO
revocada	-	BOOLEAN	Indica si la sesión fue invalidada antes de su expiración.	NO

Tabla: tokens_recuperacion

Descripción: Almacena los tokens de recuperación de contraseña y controla su vigencia y utilización.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único del token de recuperación.	NO
usuario_id	36	UUID (FK)	Usuario que solicitó la recuperación. Referencia a usuarios.id.	NO
token_hash	255	VARCHAR (IDX)	Hash del token enviado al usuario; se indexa para facilitar su búsqueda.	NO
expira_en	-	TIMESTAMPTZ	Fecha y hora de vencimiento del token.	NO
usado	-	BOOLEAN	Indica si el token ya fue utilizado.	NO
creado_en	-	TIMESTAMPTZ	Fecha y hora de creación del token.	NO

Reglas semánticas: expirado o ya usado deriva a inválido. La contraseña nueva revoca todas las sesiones del usuario.

Tabla: empresas

Descripción: Contiene las empresas evaluadas por la plataforma y la información básica de su clasificación.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único de la empresa.	NO
nombre	200	VARCHAR (UQ)	Nombre único de la empresa.	NO
sector	-	sector_empresa	Sector económico al que pertenece la empresa.	NO
activa	-	BOOLEAN	Indica si la empresa se encuentra activa en el sistema.	NO
creada_en	-	TIMESTAMPTZ	Fecha y hora de registro de la empresa.	NO

Tabla: documentos

Descripción: Registra los documentos cargados para una empresa y controla su identificación, integridad y estado de procesamiento.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único del documento.	NO
empresa_id	36	UUID (FK)	Empresa a la que pertenece el documento. Referencia a empresas.id.	NO
creado_por	36	UUID (FK)	Usuario que registró el documento. Referencia a usuarios.id.	NO
anio	-	SMALLINT	Año al que corresponde el documento.	NO
tipo	-	tipo_documento	Tipo de documento cargado.	NO
nombre_archivo	255	VARCHAR	Nombre original del archivo cargado.	NO
sha256	64	CHAR (UQ)	Huella SHA-256 única utilizada para validar integridad y evitar duplicados.	NO
tamano_bytes	-	BIGINT	Tamaño del archivo expresado en bytes.	NO
estado	-	estado_documento	Estado del documento dentro del flujo de ingesta y análisis.	NO
motivo_rechazo	-	TEXT	Motivo del rechazo cuando el documento no puede ser procesado.	SÍ
creado_en	-	TIMESTAMPTZ	Fecha y hora de registro del documento.	NO

Tabla: catalogo_gri

Descripción: Mantiene el catálogo versionado de estándares e indicadores GRI utilizados en el análisis documental.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
codigo	20	VARCHAR (PK*)	Código del estándar GRI. Forma la clave primaria compuesta con version_catalogo.	NO
serie	50	VARCHAR	Serie a la que pertenece el estándar GRI.	NO
tema	200	VARCHAR	Tema o denominación del estándar GRI.	NO
descripcion	-	TEXT	Descripción funcional del estándar o indicador.	NO
keywords	-	TEXT ARRAY	Palabras clave utilizadas para apoyar la identificación del estándar.	NO
version_catalogo	30	VARCHAR (PK*)	Versión del catálogo. Forma la clave primaria compuesta con codigo.	NO

Tabla: gri_analisis

Descripción: Almacena los resultados del análisis GRI identificados en cada documento y su eventual validación.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único del resultado de análisis GRI.	NO
documento_id	36	UUID (FK)	Documento analizado. Referencia a documentos.id.	NO
gri_codigo	20	VARCHAR (FK*)	Código GRI; integra la clave foránea compuesta hacia catalogo_gri.	NO
version_catalogo	30	VARCHAR (FK*)	Versión del catálogo; integra la clave foránea compuesta hacia catalogo_gri.	NO
fragmento_id	36	UUID (REF)	Referencia lógica al fragmento que sustenta el hallazgo en fragmentos_documento.id.	SÍ
cita_textual	-	TEXT	Texto del documento utilizado como evidencia del hallazgo.	NO
estado	-	estado_gri	Estado de revisión o validación del resultado GRI.	SÍ
validado_por	36	UUID (FK)	Usuario que validó el resultado. Referencia a usuarios.id.	SÍ
actualizado_en	-	TIMESTAMPZ	Fecha y hora de la última actualización del resultado.	NO

Tabla: sanciones**Descripción:** Registra las sanciones detectadas en los documentos y conserva la evidencia textual asociada.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único de la sanción.	NO
documento_id	36	UUID (FK)	Documento donde se identificó la sanción. Referencia a documentos.id.	NO
fragmento_id	36	UUID (REF)	Referencia lógica al fragmento de evidencia en fragmentos_documento.id.	SÍ
entidad_sanciona dora	255	VARCHAR	Nombre de la entidad que impuso la sanción.	NO
monto	14,2	NUMERIC	Importe monetario asociado a la sanción.	SÍ
moneda	10	VARCHAR	Código o denominación de la moneda del monto registrado.	SÍ
cita_textual	-	TEXT	Texto del documento que sustenta la sanción identificada.	NO
creado_en	-	TIMESTAMPTZ	Fecha y hora de registro de la sanción.	NO

Tabla: consultas_asistente**Descripción:** Registra las preguntas realizadas al asistente RAG, sus respuestas y el contexto de consulta.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único de la consulta.	NO
usuario_id	36	UUID (FK)	Usuario que realizó la consulta. Referencia a usuarios.id.	NO
empresa_id	36	UUID (FK)	Empresa utilizada como contexto. Referencia a empresas.id.	NO
anio	-	SMALLINT	Año utilizado como filtro de la consulta.	NO
pregunta	-	TEXT	Pregunta formulada por el usuario.	NO
respuesta	-	TEXT	Respuesta generada por el asistente.	NO
modelo	100	VARCHAR	Modelo de inteligencia artificial utilizado para generar la respuesta.	NO
creado_en	-	TIMESTAMPTZ	Fecha y hora de ejecución de la consulta.	NO

Tabla: consulta_citas

Descripción: Relaciona cada respuesta del asistente con los fragmentos documentales utilizados como citas o evidencia.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único de la cita.	NO
consulta_id	36	UUID (FK)	Consulta a la que pertenece la cita. Referencia a consultas_asistente.id.	NO
fragmento_id	36	UUID (REF)	Referencia lógica al fragmento citado en fragmentos_documento.id.	NO
orden	-	SMALLINT	Posición de la cita dentro de la respuesta.	NO
extracto	-	TEXT	Extracto presentado como evidencia en la respuesta.	NO

Tabla: reportes_prospeccion

Descripción: Almacena los reportes de prospección generados para cada empresa y año, junto con su contenido consolidado.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único del reporte de prospección.	NO
empresa_id	36	UUID (FK/UQ*)	Empresa del reporte. Forma una restricción única compuesta con anio.	NO
generado_por	36	UUID (FK)	Usuario que generó el reporte. Referencia a usuarios.id.	NO
anio	-	SMALLINT (UQ*)	Año del reporte. Forma una restricción única compuesta con empresa_id.	NO
pdf_path	500	VARCHAR	Ruta de almacenamiento del archivo PDF generado.	NO
sha256	64	CHAR (UQ)	Huella SHA-256 única del reporte para verificar su integridad.	NO
contenido_snaps hot	-	JSONB	Instantánea de los datos utilizados para generar el reporte.	NO
creado_en	-	TIMESTAMPTZ	Fecha y hora de generación del reporte.	NO

Tabla: auditoria

Descripción: Registra eventos relevantes del sistema para fines de trazabilidad, control y revisión.

Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único del evento de auditoría.	NO
usuario_id	36	UUID (FK)	Usuario relacionado con el evento. Referencia a usuarios.id.	SÍ
empresa_id	36	UUID (FK)	Empresa relacionada con el evento. Referencia a empresas.id.	SÍ
tipo_evento	-	tipo_evento_auditoria	Clasificación del evento registrado.	NO
detalle	-	JSONB	Información adicional y estructurada del evento.	SÍ
fecha_hora_utc	-	TIMESTAMPTZ	Fecha y hora UTC en que ocurrió el evento.	NO

Base de datos vectorial:

Tabla: fragmentos_documento

Descripción: Almacena los fragmentos extraídos de los documentos, sus embeddings y metadatos para la recuperación semántica.


Campo	Tamaño	Tipo de Dato	Descripción	NUL L
id	36	UUID (PK)	Identificador único del fragmento vectorial.	NO
documento_id	36	UUID (REF)	Referencia lógica al documento de origen en documentos.id, ubicado en la base transaccional.	NO
indice	-	INTEGER (UQ*)	Posición del fragmento dentro del documento; es única en combinación con documento_id.	NO
seccion	255	VARCHAR	Sección o encabezado del documento al que pertenece el fragmento.	SÍ
texto	-	TEXT	Contenido textual completo del fragmento.	NO
embedding	dim_fija	VECTOR	Representación vectorial del texto generada por el proveedor de embeddings.	NO
metadata	-	JSONB	Metadatos estructurados asociados al fragmento.	NO
creado_en	-	TIMESTAMPTZ	Fecha y hora de creación del fragmento.	NO

10. VOLUMEN ESTIMADO

La siguiente tabla presenta una estimación del volumen mensual de datos generado por cada módulo del sistema. Los valores son referenciales y permiten identificar los módulos con mayor demanda de almacenamiento y procesamiento.

Módulo	Volumen estimado	Nivel	Justificación
Autenticación y Gestión de Sesión	170 registros	Medio	Considera aproximadamente 168 sesiones y 2 solicitudes de recuperación de contraseña al mes.
Gestión de Usuarios	4 a 6 cuentas activas	Bajo	Referencia lógica al documento de origen en documentos.id, ubicado en la base transaccional.
Catálogo de Empresas	8 a 10 empresas	Bajo	Corresponde al registro progresivo de empresas habilitadas para el análisis.
Ingesta de Documentos	42 documentos y 4,200 fragmentos	Alto	Cada documento se divide en aproximadamente 100 fragmentos con embeddings para su almacenamiento en la base vectorial.
Análisis y Validación de Brechas GRI	425 registros	Medio	Considera aproximadamente 417 resultados de análisis y 8 sanciones identificadas. El catálogo de 40 códigos GRI permanece como información base.
Asistente de Inteligencia Artificial (RAG)	1,670 registros	Alto	Considera aproximadamente 420 consultas y 1,250 citas, con un promedio de tres citas por respuesta.
Generación de Reportes de Prospección	8 a 10 reportes	Bajo	Los reportes se generan únicamente para empresas con información analizada y validada.
Auditoría Funcional	420 eventos	Medio	Registra accesos, cambios de usuarios, ingestas, rechazos de documentos y generación de reportes.

11. DISEÑO ARQUITECTÓNICO



12. PROTOTIPO

13. ANEXO

-